编译专题实验报告

词法分析器

计算机2101 陈实

完成模式：独立完成

实验平台

1. 操作系统：WSL2 Ubuntu 20.04
2. flex 版本：2.6.4
3. GCC 版本：11.4.0

实验目的

1. 目的：构建词法分析程序能将源语言程序作为输入，并输出词法记号串到文件中。
2. 功能：
    1. 单词设计包含主文法中所有词法单位；
    2. 一遍扫描或含预处理遍，能删除注解，并允许空白字符串作为分隔；
    3. 分析框架scanner()允许连续调用直到输入串被扫描完毕，每调用一次返回一个记号；
    4. 有联合DFA设计结果以及超前搜索功能；
    5. (可选)词法错误处理。

实验内容

1. flex 声明部分：

```
%option yylineno

%{
        #include<stdio.h>
        #include<stdlib.h>
        #include<string.h>

    enum token{
        ID = 258,
        NUM = 259,
        FLO = 260,
        AAA = 261,
        ADD = 262,
        MUL = 263,
        ROP = 264,
        ASG = 265,
        LPA = 266,
        RPA = 267,
        LBK = 268,
        RBK = 269,
        LBR = 270,
```

```
        RBR = 271,
        CMA = 272,
        SCO = 273,
        INT = 274,
        FLOAT = 275,
        DOUBLE = 276,
        FOR = 277,
        IF = 278,
        ELSE = 279,
        WHILE = 280,
        RETURN = 281,
        INPUT = 282,
        PRINT = 283,
        VOID = 284,
        STRING = 285,
    };

    typedef union {
        char *str;
        int num;
        float flo;
    } YYSTYPE;

%}
```

1. 定义了词法记号的枚举类型，包括了主文法中的所有词法单位；
2. 定义了 YYSTYPE 联合体，用于存储词法记号的值。
3. 引入了头文件，声明了一些函数。
4. 使用了 `%option yylineno` 选项，使得 flex 会在词法分析时记录行号。
5. 使用了 `%{ ... %}` 语法，将 C 代码插入到生成的词法分析器中。

2. flex 正则式部分：

```
STR \"(\\.|[^\\"])*\"
ID [a-z][a-z0-9]*
NUM [+-]?[0-9]+
FLO [+-]?([0-9]*\.[0-9]+|[0-9]+\.[0-9]*)
AAA \+\+
ADD "+"
MUL "*"
ROP ("=="|"<"|"<=")
ASG "="
LPA "("
RPA ")"
LBK "["
RBK "]"
LBR "{"
RBR "}"
CMA ","
SCO ";"
INT int
FLOAT float
DOUBLE double
FOR for
```

```
IF if
ELSE else
WHILE while
RETURN return
INPUT input
PRINT print
VOID void
STRING string
SINGLE_COMMENT \/\/[^\n]*
MULTI_COMMENT \/\*([^*]|\*+[^/])*\*+\/
```

1. 定义了正则式，用于识别源语言中的各种词法单位。
2. 应该注意到，keyword会同时匹配到ID和keyword，因此需要在规则中进行判断
3. 列举几个重要的正则式：
    1. ID：匹配一个以小写字母开头，后面跟着小写字母或数字的字符串。
    2. STR：匹配一个以双引号开头，双引号结尾的字符串。
    3. SINGLE_COMMENT：匹配一个以 `//` 开头的单行注释。
    4. MULTI_COMMENT：匹配一个以 `/*` 开头，`*/` 结尾的多行注释，`([^*]|\*+[^/])*` 详解：
        - `([^*])`：表示单个非星号的字符。这意味着任何不包含星号的字符都可以匹配。
        - `(*+[^/])`：表示一个或多个星号后跟一个非斜杠的字符。这意味着，如果星号存在，必须有至少一个跟随的非斜杠字符。
        - `([^*]|*+[^/])`：这个部分结合了两者的逻辑或。这意味着它可以匹配非星号的字符，或者一个或多个星号后跟非斜杠的字符。
        - `([^]|*+[^/])`：外面的星号表示上述模式可以重复零次或多次。这意味着这个正则表达式可以匹配任意长度的字符序列，前提是符合以上两个子部分的规则。

3. flex 规则部分：

```
{SINGLE_COMMENT} {}
{MULTI_COMMENT} {}
{STR} {printf("line %2d:(STR,%s)\n",yylineno,yytext);return STRING;}
{INT} {printf("line %2d:(INT,-)\n",yylineno);return INT;}
{FLOAT} {printf("line %2d:(FLOAT,-)\n",yylineno);return FLOAT;}
{DOUBLE} {printf("line %2d:(DOUBLE,-)\n",yylineno);return DOUBLE;}
{FOR} {printf("line %2d:(FOR,-)\n",yylineno);return FOR;}
{IF} {printf("line %2d:(IF,-)\n",yylineno);return IF;}
{ELSE} {printf("line %2d:(ELSE,-)\n",yylineno);return ELSE;}
{WHILE} {printf("line %2d:(WHILE,-)\n",yylineno);return WHILE;}
{RETURN} {printf("line %2d:(RETURN,-)\n",yylineno);return RETURN;}
{INPUT} {printf("line %2d:(INPUT,-)\n",yylineno);return INPUT;}
{PRINT} {printf("line %2d:(PRINT,-)\n",yylineno);return PRINT;}
{VOID} {printf("line %2d:(VOID,-)\n",yylineno);return VOID;}
{STRING} {printf("line %2d:(STRING,-)\n",yylineno);return STRING;}
{ID} {printf("line %2d:(ID,%s)\n",yylineno,yytext);return ID;}
{NUM} {printf("line %2d:(NUM,%s)\n",yylineno,yytext);return NUM;}
{FLO} {printf("line %2d:(FLO,%s)\n",yylineno,yytext);return FLO;}
{AAA} {printf("line %2d:(AAA,-)\n",yylineno);return AAA;}
{ADD} {printf("line %2d:(ADD,-)\n",yylineno);return ADD;}
{MUL} {printf("line %2d:(MUL,-)\n",yylineno);return MUL;}
{ROP} {printf("line %2d:(ROP,-)\n",yylineno);return ROP;}
{ASG} {printf("line %2d:(ASG,-)\n",yylineno);return ASG;}
{LPA} {printf("line %2d:(LPA,-)\n",yylineno);return LPA;}
```

```
{RPA} {printf("line %2d:(RPA,-)\n",yylineno);return RPA;}
{LBK} {printf("line %2d:(LBK,-)\n",yylineno);return LBK;}
{RBK} {printf("line %2d:(RBK,-)\n",yylineno);return RBK;}
{LBR} {printf("line %2d:(LBR,-)\n",yylineno);return LBR;}
{RBR} {printf("line %2d:(RBR,-)\n",yylineno);return RBR;}
{CMA} {printf("line %2d:(CMA,-)\n",yylineno);return CMA;}
{SCO} {printf("line %2d:(SCO,-)\n",yylineno);return SCO;}
[ \t] {}
\n {}

```

1. 定义了规则，用于识别源语言中的各种词法单位。当匹配到一个词法单位时，操作系统会执行对应的代码块，并返回对应的词法记号。
2. 正则匹配有多义性，flex对此有两个优先级规则：
    1. 匹配长度最长的最优先
    2. 当匹配长度相同时，按照规则的顺序匹配
3. 对于关键字，如 `int`，`float` 等，需要在规则，将其匹配规则放在ID之前，否则会被匹配为ID。
4. 为了实现处理的时候忽略空白字符，需要在规则中加入 `[ \t]` 和 `\n` 规则。同时将其置为空操作。
5. 对于注释，需要在规则中加入对应的规则，将其置为空操作。

4. 主函数部分：

```c
void yyerror(char *s) {
    fprintf(stderr, "%s\n", s);
}

void redirect_output_to_file(const char *filename) {
    FILE *file = freopen(filename, "w", stdout);
    if (file == NULL) {
        fprintf(stderr, "无法打开文件 %s\n", filename);
        exit(1);
    }
}

int main() {
    redirect_output_to_file("output.txt");
    while (yylex() != 0);
    return 0;
}
```

1. 定义了 `yyerror` 函数，用于处理词法错误。
2. 定义了 `redirect_output_to_file` 函数，用于将输出重定向到文件：`output.txt`。
3. 在 `main` 函数中，调用 `redirect_output_to_file` 函数，将输出重定向到文件，然后循环调用 `yylex` 函数，直到返回值为 `0`。
4. 返回值为 `0` 时，表示词法分析结束，退出程序。
5. 由于 `yylex` 函数会返回词法记号，因此在循环中，每次调用 `yylex` 函数，都会输出一个词法记号到文件中。
6. 由于 `yylex` 函数返回值为 `0` 时，表示词法分析结束，因此循环结束，退出程序。

5. Makefile 文件：

```
ALL: lex.exe

```

```
lex.exe: lex.yy.c
        @gcc -o $@ lex.yy.c -ll
        @./$@ < test.txt
        @rm -rf lex.yy.c lex.exe
        @cat output.txt

lex.yy.c: lex.l
        @flex lex.l

clean:
        @rm -rf lex.yy.c lex.exe output.txt
        @ls

.PHONY: clean
```

1. 定义了 `ALL` 目标，依赖于 `lex.exe` 目标。
2. 定义了 `lex.exe` 目标，依赖于 `lex.yy.c` 文件。
3. 在 `lex.exe` 目标中，使用 `gcc` 命令编译 `lex.yy.c` 文件，生成可执行文件 `lex.exe`，然后运行 `lex.exe`，将 `test.txt` 文件作为输入，将输出重定向到 `output.txt` 文件，最后删除 `lex.yy.c` 文件和 `lex.exe` 文件，输出 `output.txt` 文件。

实验结果

1. 测试文件：`test.txt`

```
//This is a test file
int main() {
    int a = 1;
    float b = 2.3;
    if (a < b) {
        printf("a < b\n");
    } else {
        printf("a ≥ b\n");
    }
}
```

2. 在命令行输入 `make` 命令，编译运行程序。

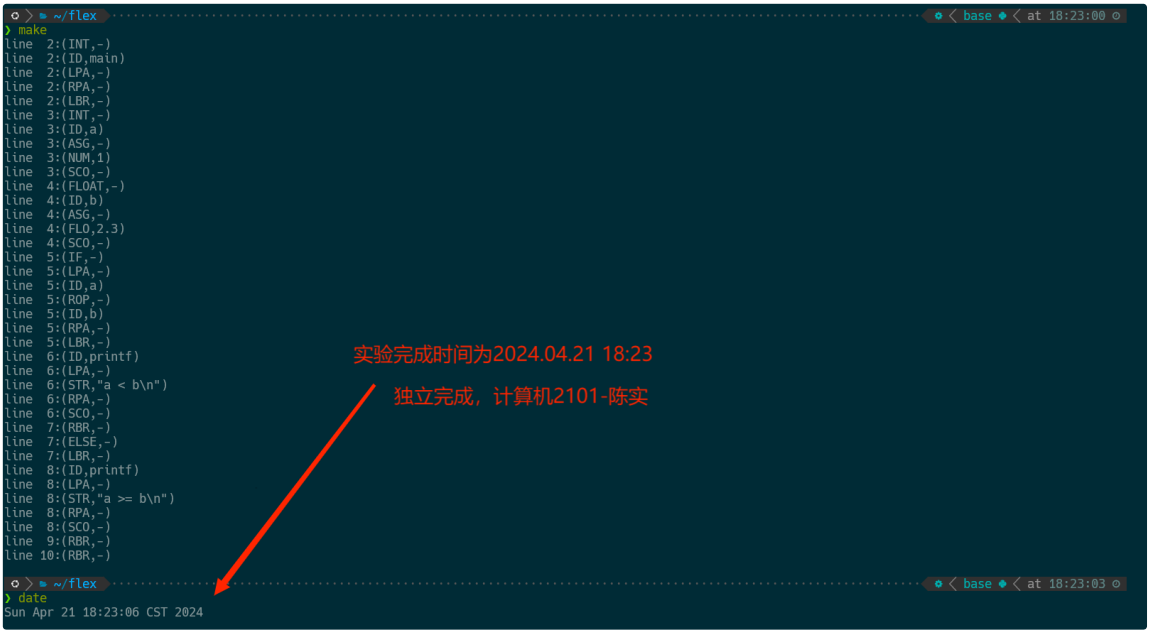


```
line  2:(INT,-)
line  2:(ID,main)
line  2:(LPA,-)
line  2:(RPA,-)
line  2:(LBR,-)
line  3:(INT,-)
line  3:(ID,a)
line  3:(ASG,-)
line  3:(NUM,1)
line  3:(SCO,-)
line  4:(FLOAT,-)
line  4:(ID,b)
line  4:(ASG,-)
line  4:(FLO,2.3)
line  4:(SCO,-)
line  5:(IF,-)
line  5:(LPA,-)
line  5:(ID,a)
line  5:(ROP,-)
line  5:(ID,b)
line  5:(RPA,-)
line  5:(LBR,-)
line  6:(ID,printf)
line  6:(LPA,-)
line  6:(STR,"a < b\n")
line  6:(RPA,-)
line  6:(SCO,-)
line  7:(RBR,-)
line  7:(ELSE,-)
line  7:(LBR,-)
line  8:(ID,printf)
line  8:(LPA,-)
line  8:(STR,"a ⩾ b\n")
line  8:(RPA,-)
line  8:(SCO,-)
line  9:(RBR,-)
line 10:(RBR,-)
```

3. 实验结果分析
    1. 能正确识别源语言中的各种词法单位。
    2. 能正确区分关键字和标识符。
    3. 能正确过滤注释。
    4. 能正确识别字符串。

实验总结

遇到的问题

1. 在编写正则式时，没有考虑到关键字和标识符的问题，导致关键字被匹配为ID。
   解决方法：将关键字的正则式放在ID之前。
2. Float的正则式写错，导致无法识别浮点数。
   解决方法：修改正则式。
3. 命令操作繁琐，需要手动编译运行。
   解决方法：编写Makefile文件，简化操作。

实验心得

1. 通过本次实验，我学会了使用 flex 工具编写词法分析器。
2. 了解了 flex 的基本用法，包括声明部分、正则式部分、规则部分。
3. 学会了使用 flex 编写正则式，识别源语言中的各种词法单位。
4. 学会了使用 Makefile 文件，简化编译运行操作。
5. 通过本次实验，我对词法分析有了更深入的了解，对编译原理有了更深刻的认识。

附录

1. 实验代码 lex.l

```
%option yylineno

%{
        #include<stdio.h>
        #include<stdlib.h>
        #include<string.h>

    enum token{
        ID = 258,
        NUM = 259,
        FLO = 260,
        AAA = 261,
        ADD = 262,
        MUL = 263,
        ROP = 264,
        ASG = 265,
        LPA = 266,
        RPA = 267,
        LBK = 268,
        RBK = 269,
```

```
        LBR = 270,
        RBR = 271,
        CMA = 272,
        SCO = 273,
        INT = 274,
        FLOAT = 275,
        DOUBLE = 276,
        FOR = 277,
        IF = 278,
        ELSE = 279,
        WHILE = 280,
        RETURN = 281,
        INPUT = 282,
        PRINT = 283,
        VOID = 284,
        STRING = 285,
    };

    typedef union {
        char *str;
        int num;
        float flo;
    } YYSTYPE;

%}

YYSTYPE yylval;

STR \"(\\.|[^\\"])*\"
ID [a-z][a-z0-9]*
NUM [+-]?[0-9]+
FLO [+-]?([0-9]*\.[0-9]+|[0-9]+\.[0-9]*)
AAA \+\+
ADD "+"
MUL "*"
ROP ("=="|"<"|"<=")
ASG "="
LPA "("
RPA ")"
LBK "["
RBK "]"
LBR "{"
RBR "}"
CMA ","
SCO ";"
INT int
FLOAT float
DOUBLE double
FOR for
IF if
ELSE else
WHILE while
RETURN return
INPUT input
```

```
PRINT print
VOID void
STRING string
SINGLE_COMMENT \/\/[^\n]*
MULTI_COMMENT \/\*([^*]|\*+[^/])*\*+\/

%%
{SINGLE_COMMENT} {}
{MULTI_COMMENT} {}
{STR} {printf("line %2d:(STR,%s)\n",yylineno,yytext);return STRING;}
{INT} {printf("line %2d:(INT,-)\n",yylineno);return INT;}
{FLOAT} {printf("line %2d:(FLOAT,-)\n",yylineno);return FLOAT;}
{DOUBLE} {printf("line %2d:(DOUBLE,-)\n",yylineno);return DOUBLE;}
{FOR} {printf("line %2d:(FOR,-)\n",yylineno);return FOR;}
{IF} {printf("line %2d:(IF,-)\n",yylineno);return IF;}
{ELSE} {printf("line %2d:(ELSE,-)\n",yylineno);return ELSE;}
{WHILE} {printf("line %2d:(WHILE,-)\n",yylineno);return WHILE;}
{RETURN} {printf("line %2d:(RETURN,-)\n",yylineno);return RETURN;}
{INPUT} {printf("line %2d:(INPUT,-)\n",yylineno);return INPUT;}
{PRINT} {printf("line %2d:(PRINT,-)\n",yylineno);return PRINT;}
{VOID} {printf("line %2d:(VOID,-)\n",yylineno);return VOID;}
{STRING} {printf("line %2d:(STRING,-)\n",yylineno);return STRING;}
{ID} {printf("line %2d:(ID,%s)\n",yylineno,yytext);return ID;}
{NUM} {printf("line %2d:(NUM,%s)\n",yylineno,yytext);return NUM;}
{FLO} {printf("line %2d:(FLO,%s)\n",yylineno,yytext);return FLO;}
{AAA} {printf("line %2d:(AAA,-)\n",yylineno);return AAA;}
{ADD} {printf("line %2d:(ADD,-)\n",yylineno);return ADD;}
{MUL} {printf("line %2d:(MUL,-)\n",yylineno);return MUL;}
{ROP} {printf("line %2d:(ROP,-)\n",yylineno);return ROP;}
{ASG} {printf("line %2d:(ASG,-)\n",yylineno);return ASG;}
{LPA} {printf("line %2d:(LPA,-)\n",yylineno);return LPA;}
{RPA} {printf("line %2d:(RPA,-)\n",yylineno);return RPA;}
{LBK} {printf("line %2d:(LBK,-)\n",yylineno);return LBK;}
{RBK} {printf("line %2d:(RBK,-)\n",yylineno);return RBK;}
{LBR} {printf("line %2d:(LBR,-)\n",yylineno);return LBR;}
{RBR} {printf("line %2d:(RBR,-)\n",yylineno);return RBR;}
{CMA} {printf("line %2d:(CMA,-)\n",yylineno);return CMA;}
{SCO} {printf("line %2d:(SCO,-)\n",yylineno);return SCO;}
[ \t] {}
\n {}

%%

void yyerror(char *s) {
    fprintf(stderr, "%s\n", s);
}

void redirect_output_to_file(const char *filename) {
    FILE *file = freopen(filename, "w", stdout);
    if (file == NULL) {
        fprintf(stderr, "无法打开文件 %s\n", filename);
        exit(1);
    }
}
```

```

int main() {
    redirect_output_to_file("output.txt");
    while (yylex() != 0);
    return 0;
}
int yywrap()
{
        return 1;
}
```

2. Makefile 文件：Makefile

```
ALL: lex.exe
lex.exe: lex.yy.c
        @gcc -o $@ lex.yy.c -ll
        @./$@ < test.txt
        @rm -rf lex.yy.c lex.exe
        @cat output.txt

lex.yy.c: lex.l
        @flex lex.l

clean:
        @rm -rf lex.yy.c lex.exe output.txt
        @ls

.PHONY: clean
```

3. 测试文件 test.txt

```
//This is a test file
int main() {
    int a = 1;
    float b = 2.3;
    if (a < b) {
        printf("a < b\n");
    } else {
        printf("a ≥ b\n");
    }
}
```